Le dataset USCRN

Analyse de la donnée et sélection des 5 stations

Résumé. Le réseau USCRN compte 159 stations. Après avoir écarté celles qui ne couvrent pas les quatre années et celles dont le capteur d'humidité du sol est inactif, 115 restaient en lice. Un test de disponibilité réelle en a éliminé 60 %. Les 5 stations retenues couvrent 5 climats nettement distincts, et deux d'entre elles ont une station jumelle à proximité.

1. Qu'est-ce que c'est

U.S. Climate Reference Network — un réseau de stations de mesure installées au sol, géré par la NOAA. Ce sont de **vraies mesures de capteurs**, pas une estimation calculée.

Point	Détail
Source	NOAA / NCEI — produit **hourly02**
Lien	www.ncei.noaa.gov/pub/data/uscrn/products/hourly02/
Accès	libre, sans compte
Format	fichiers texte (.txt), **un par station et par année**, environ 1,6 Mo chacun
Résolution	**horaire** — 8 760 lignes par an et par station
Couverture	2000 à aujourd'hui ; nous utilisons **2022 à 2025**
Colonnes	38 au total

1.1 Ce que mesure une station

Groupe de colonnes	Contenu
Identification	numéro de station, date et heure (UTC et locale), latitude, longitude
Température de l'air	moyenne horaire, maximum, minimum
Précipitations	cumul sur l'heure
Rayonnement solaire	moyenne, maximum, minimum, avec drapeau qualité
Température de surface	moyenne, maximum, minimum, avec drapeau qualité
Humidité relative	moyenne horaire, avec drapeau qualité
Humidité du sol	à **5, 10, 20, 50 et 100 cm** de profondeur
Température du sol	aux 5 mêmes profondeurs

La colonne cible est SOIL_MOISTURE_5 — l'humidité du sol à 5 cm. C'est la grandeur que le système doit protéger.

Deux atouts de ce dataset. D'abord, une même station fournit à la fois l'humidité du sol *et* ses causes physiques : la pluie qui la fait monter, la température et le rayonnement qui la font baisser. Ensuite, les 5 profondeurs donnent un contrôle de cohérence verticale gratuit : si l'humidité à 5 cm bondit sans que celle à 10 cm ne bouge, c'est physiquement impossible.

1.2 Les valeurs manquantes

Elles ne sont pas vides, elles sont **codées**. Si on ne les traite pas, toutes les statistiques sont fausses.

Colonnes	Code de valeur manquante
Humidité du sol	**-99.000**
Températures, température du sol	**-9999**
Rayonnement solaire	**-99999**

2. Pourquoi 5 stations fixes sur 4 années

Le découpage retenu est **temporel** : 2022-2023 pour l'entraînement, 2024 pour la validation, 2025 pour le test final. Les stations doivent donc être **les mêmes** d'un bout à l'autre. Si elles changeaient, une baisse de performance sur 2025 serait impossible à interpréter : viendrait-elle de l'année, ou du changement de stations ?

Trois raisons s'ajoutent. Les indices de pluie cumulée remontent jusqu'à 30 jours en arrière et ont besoin d'un historique continu. Le comportement « normal » d'une station ne se construit qu'avec plusieurs années — avec un seul janvier, impossible de savoir s'il était normal ou exceptionnel. Et le modèle One-Class apprend la signature propre de chaque capteur, donc il lui faut du temps sur le même capteur.

Cible : 5 stations × 4 années = 20 fichiers.

3. Les critères de sélection

3.1 Trois critères éliminatoires

#	Critère	Pourquoi
1	Présente sur **les 4 années**	Une station arrêtée en 2024 est inutilisable, même excellente avant.
2	**Capteur d'humidité du sol actif**	Toutes les stations n'en ont pas. Vérifié sur une station d'Alaska : toutes les colonnes sol valent -99.000, le fichier est inexploitable pour nous.
3	**Disponibilité ≥ 90 %**	Une station à 40 % de trous apporte moins de signal qu'elle n'introduit de bruit.

3.2 Un critère de qualité : la diversité climatique

C'est le point le plus important après les critères durs. Le système doit apprendre qu'une même variation d'humidité peut être **normale dans un contexte et suspecte dans un autre**. Cinq stations dans la même région reviendraient à n'apprendre qu'un seul climat — le modèle s'effondrerait partout ailleurs.

Cinq régimes ont été définis, chacun apportant une difficulté différente :

Climat	Ce qu'il apporte au modèle
Aride	Sol sec en permanence : toute hausse d'humidité est forcément suspecte. Le cas le plus facile.
Plaines semi-arides	Alternance sec/humide marquée. Le cas intermédiaire.
Subtropical humide	Pluies fréquentes : un orage et une injection se ressemblent. **Le cas difficile**.
Continental froid	Le gel fait chuter l'humidité mesurée sans aucune attaque. **Le piège à faux positifs**.
Méditerranéen	Saison sèche et saison humide tranchées — **le climat de la Tunisie**.

4. La méthode de test

La sélection a été automatisée plutôt que faite à la main, pour être reproductible et vérifiable. Quatre étapes :

Étape	Ce qui est fait
1	Lecture des listings des quatre années et intersection : on ne garde que les stations présentes partout.
2	Exclusion de l'Alaska et de Hawaï (pas de sondes dans le sol), puis affectation de chaque station à son groupe climatique.
3	Téléchargement de l'année 2025 pour chaque candidate, et mesure de la part réelle de valeurs valides sur SOIL_MOISTURE_5.
4	Classement par groupe climatique et export du tableau complet.

Le test ne porte que sur 2025 : c'est l'année de test final, la plus exigeante, et une station défaillante en 2025 est de toute façon inutilisable. Cela évitait de télécharger 460 fichiers.

5. Les résultats

Étape du filtrage	Stations restantes
Réseau USCRN complet	159
Présentes sur les 4 années 2022-2025	**156**
Hors Alaska et Hawaï, dans un groupe climatique	**115**
Disponibilité ≥ 90 % sur SOIL_MOISTURE_5	**46** — soit 60 % d'élimination

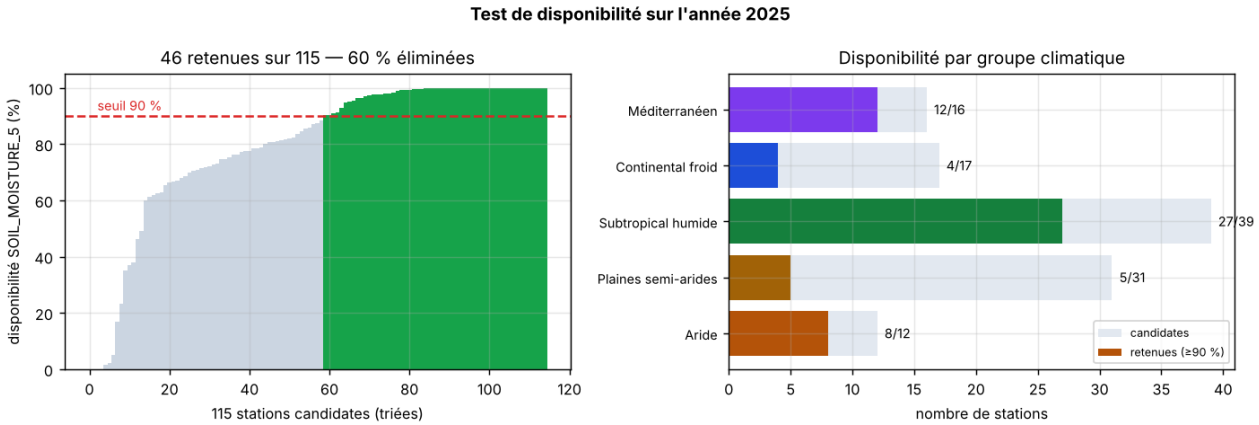


Figure 1 — À gauche, la disponibilité des 115 candidates, triée. La distribution est nettement **bimodale** : une station fonctionne bien ou pas du tout, il y a très peu de cas intermédiaires. Le seuil à 90 % n'est donc pas arbitraire, il tombe dans un vide. À droite, le taux de réussite par climat.

Le résultat le plus utile est la rareté par climat. Le subtropical humide offre 27 stations exploitables sur 39, mais le continental froid n'en offre que **4 sur 17**, et les plaines semi-arides **5 sur 31**. Pour ces deux groupes le choix est très contraint — ce qui justifie d'avoir testé toutes les candidates plutôt que quelques-unes prises au hasard.

6. Une trouvaille : les stations jumelles

En examinant la liste complète, plusieurs sites apparaissent **deux fois** : deux stations distinctes à faible distance l'une de l'autre, toutes deux exploitables.

Paire	Distance	Disponibilité
OK_Goodwell_2_E + **OK_Goodwell_2_SE**	**3,8 km**	96,9 % / 97,4 %
AL_Selma_13_WNW + **AL_Selma_6_SSE**	28,4 km	100 % / 99,7 %
GA_Newton_11_SW + GA_Newton_8_W	—	100 % / 100 %
NC_Asheville_13_S + NC_Asheville_8_SSW	—	98,2 % / 99,7 %

Pourquoi c'est précieux. Deux capteurs distants de quelques kilomètres mesurent le même sol sous la même météo. Leurs mesures doivent évoluer ensemble. Si l'une diverge et pas l'autre, l'anomalie est établie **sans avoir besoin d'aucune source externe**.

> Cela donne un contrôle de cohérence spatiale autonome, et une démonstration directe pour la soutenance : on injecte une attaque sur une station, sa jumelle ne bouge pas, la contradiction est visible immédiatement.

La paire de Goodwell est la plus forte : 3,8 km seulement, donc même sol, même météo, même régime hydrique. Celle de Selma est plus éloignée (28 km) et les deux stations montrent des plages d'humidité différentes (0,127-0,548 contre 0,036-0,294), signe de sols distincts — utile, mais moins directement comparable.

7. La sélection finale

Climat	Station	Dispo 2025	Pluie 2025	T moyenne	Latitude	Longitude
Aride	**AZ_Tucson_11_W**	100 %	185 mm	22,4 °C	32.24	-111.17
Plaines semi-arides	**OK_Goodwell_2_E**	96,9 %	461 mm	14,2 °C	36.60	-101.59
Subtropical humide	**AL_Selma_13_WNW**	100 %	1 349 mm	17,8 °C	32.46	-87.24
Continental froid	**NY_Ithaca_13_E**	100 %	1 035 mm	7,9 °C	42.44	-76.25
Méditerranéen	**CA_Fallbrook_5_NE**	100 %	382 mm	17,4 °C	33.44	-117.19

Jumelles proposées en complément : **OK_Goodwell_2_SE** (36.57 / -101.61) et **AL_Selma_6_SSE** (32.33 / -86.98) — 8 fichiers de plus.

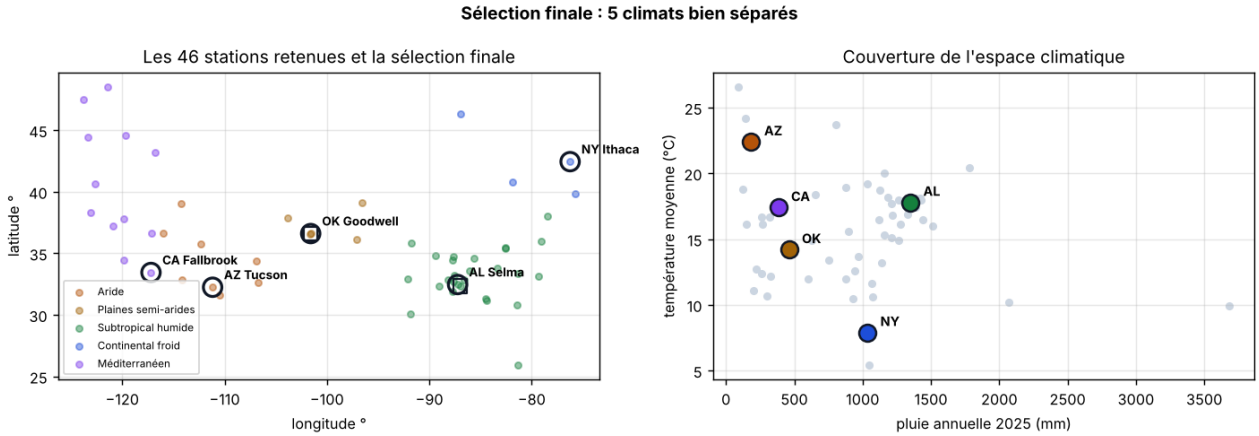


Figure 2 — À gauche, les 46 stations retenues ; cercles noirs = sélection finale, carrés = jumelles. À droite, les cinq stations dans l'espace pluie-température : elles occupent des zones bien distinctes, ce qui était l'objectif.

7.1 Les deux arbitrages

Plaines semi-arides : Goodwell plutôt que Stillwater. Stillwater arrivait premier au classement (99,9 % contre 96,9 %), mais il reçoit **896 mm** de pluie par an — presque autant que les stations subtropicales. Il aurait fait doublon au lieu d'apporter un climat distinct. Goodwell reçoit **461 mm** : c'est un vrai régime semi-aride, et il a une jumelle à 3,8 km. Trois points de disponibilité sacrifiés pour un climat réellement différent et un contrôle spatial gratuit.

Méditerranéen : Fallbrook plutôt que Bodega. Les deux sont à 100 %. Bodega est sur la côte pacifique, 599 mm et brouillard fréquent — or la mesure satellite est peu fiable près du littoral, ce qui compliquerait l'alignement spatial. Fallbrook est plus sec (382 mm) et plus chaud, donc plus proche du climat tunisien.

Réserve à signaler. L'humidité minimale de Fallbrook est de 0,113 : le sol ne s'assèche jamais complètement, probablement du fait d'irrigation à proximité. Si l'on préfère une amplitude plus large, Bodega (minimum 0,018) reste le repli.

8. Ce qui reste à vérifier

Le test de disponibilité n'a porté que sur **2025**. L'existence des fichiers est confirmée pour les quatre années, mais pas encore leur qualité. Rien ne garantit qu'une station à 100 % en 2025 l'était aussi en 2022 : un capteur a pu être remplacé, tomber en panne plusieurs mois, ou être recalibré.

Le même calcul doit donc être relancé sur 2022, 2023 et 2024 une fois les 20 fichiers téléchargés. Si une station s'effondre sur une année, elle est remplacée — il reste 41 candidates au-dessus de 90 %.

Point de vigilance. En climat continental froid, il n'y a que 4 stations exploitables sur 17. Si Ithaca pose problème, la seule alternative sérieuse est OH_Wooster_3_SSE. C'est le groupe le plus fragile de la sélection.