Dataset USCRN — livraison

5 stations, 5 climats, 4 années — nettoyé, validé, prêt à l'emploi

Résumé. 210 384 observations horaires sur six stations (cinq climats plus une station jumelle), de janvier 2022 à décembre 2025. Aucune rupture temporelle. Le contrôle a mis au jour trois choses qu'un simple comptage de valeurs manquantes n'aurait pas montrées : les trous de données sont causés par le gel du sol et non par des pannes, les deux stations jumelles ont un décalage systématique qu'il faut retirer avant toute comparaison, et le seuil du contrôle spatial peut être calibré sur les données plutôt que choisi arbitrairement.

1. Le dataset livré

Caractéristique	Valeur
Observations	**210 384** lignes horaires
Stations	6 — cinq climats distincts plus une jumelle
Période	1er janvier 2022 → 31 décembre 2025
Par station	35 064 heures, **sans aucune rupture**
Variable cible	**SOIL_MOISTURE_5** — humidité du sol à 5 cm (m^3/m^3)
Variables de contexte	pluie, rayonnement solaire, température de l'air et de surface, humidité relative, humidité et température du sol aux 5 profondeurs
Format	Parquet (3,8 Mo), une ligne = une station à une heure
Clé	time (UTC) + station

1.1 Les stations

Climat	Station	Latitude	Longitude	Pluie/an	T moy	Humidité sol
Aride	**AZ_Tucson_11_W**	32.24	-111.17	223 mm	22,1 °C	0,012 – 0,275
Plaines semi-arides	**OK_Goodwell_2_SE**	36.57	-101.61	443 mm	14,3 °C	0,068 – 0,499
Subtropical humide	**MS_Newton_5_ENE**	32.34	-89.07	1 439 mm	17,8 °C	0,054 – 0,409
Continental froid	**NY_Ithaca_13_E**	42.44	-76.25	1 047 mm	8,5 °C	0,098 – 0,523
Méditerranéen	**CA_Fallbrook_5_NE**	33.44	-117.19	428 mm	17,1 °C	0,113 – 0,349
jumelle (3,8 km)	*OK_Goodwell_2_E*	36.60	-101.59	454 mm	14,2 °C	0,009 – 0,512

Facteur 6,5 entre la station la plus sèche et la plus humide, 14 °C d'écart de température moyenne. La diversité recherchée est bien là.

2. Les cinq climats, vus dans les données

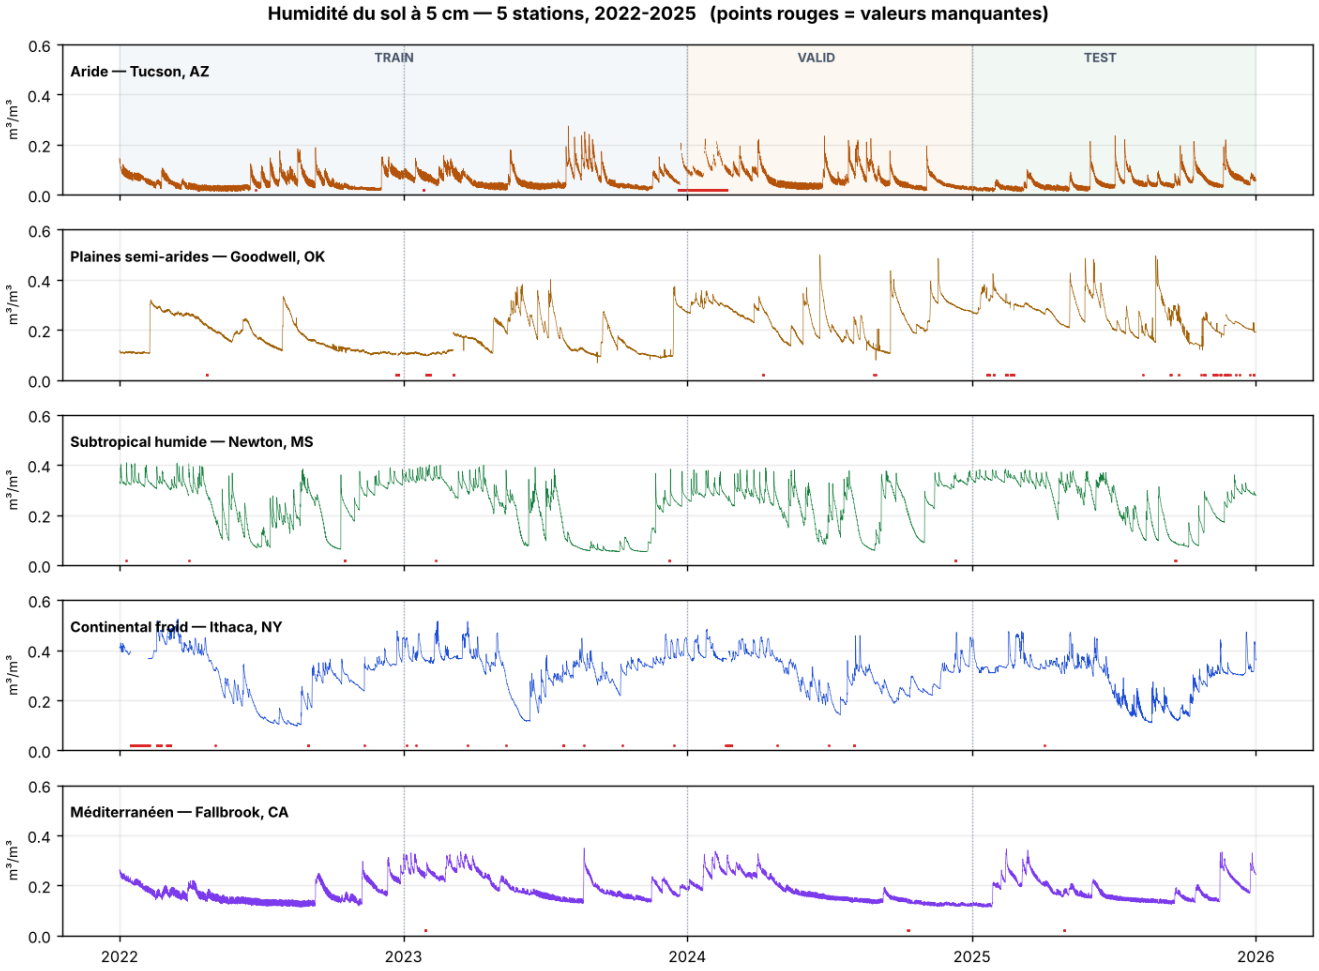


Figure 1 — Chaque climat a une signature visuelle propre. **Tucson** montre des pics de pluie isolés suivis d'un assèchement rapide, sur un fond quasi nul. **Newton** reste élevé en permanence avec des oscillations serrées. **Fallbrook** dessine le cycle méditerranéen à l'état pur : déclin lent tout l'été, recharge brutale en hiver — c'est le comportement le plus proche du sol tunisien. **Ithaca** présente des hivers hachés, expliqués en section 4. Les bandes colorées en haut marquent le découpage entraînement / validation / test.

3. Qualité des données

3.1 Disponibilité par période du découpage

Station	TRAIN 2022-23	VALID 2024	TEST 2025
CA_Fallbrook_5_NE	100,0	100,0	100,0
MS_Newton_5_ENE	99,9	100,0	100,0
OK_Goodwell_2_SE	99,2	99,9	97,4
AZ_Tucson_11_W	99,1	92,2	100,0
NY_Ithaca_13_E	96,5	98,8	100,0
OK_Goodwell_2_E (jumelle)	*83,9*	*96,1*	*96,9*

Aucune des cinq stations principales ne descend sous 92 % sur une période entière. La jumelle est plus faible sur 2022 (panne de janvier à avril) mais cela ne pénalise pas son rôle : le contrôle de cohérence spatiale ne s'applique qu'aux heures où les deux stations mesurent, soit 89,8 % du temps.

3.2 Continuité temporelle

Chaque station compte exactement **35 064 lignes** et un seul type d'intervalle entre deux observations consécutives : une heure. Aucun doublon, aucun saut, y compris aux passages du 31 décembre au 1er janvier — le point le plus fragile après concaténation de quatre fichiers annuels.

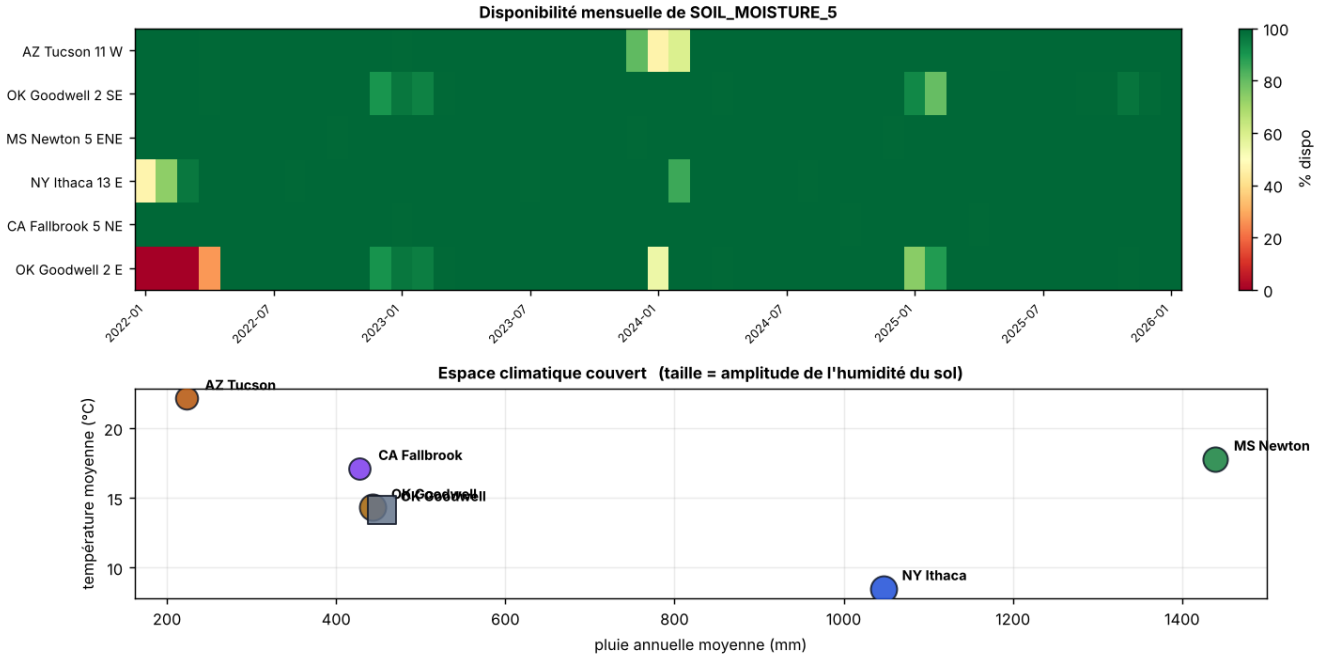


Figure 2 — En haut, la disponibilité mois par mois. Les trous ne sont pas dispersés au hasard : ils forment des blocs, signe de pannes franches plutôt que de bruit de mesure. En bas, les six stations dans l'espace pluie-température ; la taille des marqueurs donne l'amplitude de l'humidité du sol.

4. Trois résultats du contrôle qualité

4.1 Les trous de données sont causés par le gel

C'est le résultat le plus utile, et il contredit l'hypothèse de départ. On pouvait craindre que le gel provoque des chutes d'humidité trompeuses, donc des fausses alertes. Les données montrent autre chose : **quand le sol gèle, la sonde cesse purement et simplement de rapporter.**

Station	Heures manquantes	dont sol sous 1 °C	Part
NY_Ithaca_13_E	727	701	**96 %**
OK_Goodwell_2_SE	376	324	**86 %**
OK_Goodwell_2_E	3 432	698	20 %
AZ_Tucson_11_W	841	0	0 %

La sonde mesure l'eau liquide par une méthode diélectrique ; dans un sol gelé la mesure n'a plus de sens, et la NOAA l'écarte. Les trous d'Ithaca sont donc **explicables et prévisibles**, pas des défaillances matérielles.

Conséquence pratique. Ces heures ne doivent pas être comblées par interpolation : cela reviendrait à inventer des valeurs dans les conditions précises où la physique du capteur ne s'applique plus. Il faut les laisser vides et marquer la période comme hors domaine. En contrepartie, le système de détection a un angle mort hivernal sur les stations froides, qu'il vaut mieux documenter que masquer.

4.2 Les stations jumelles ont un décalage systématique

Les deux stations de Goodwell sont distantes de 3,8 km et leurs mesures sont corrélées à **0,907**. Mais elles ne sont pas interchangeables : **Goodwell 2_SE lit en moyenne 0,056 m^3/m^3 de plus que 2_E, et cela dans 95,3 % des heures.** Ce n'est pas du bruit, c'est un décalage constant — sols légèrement différents, ou calibrations différentes.

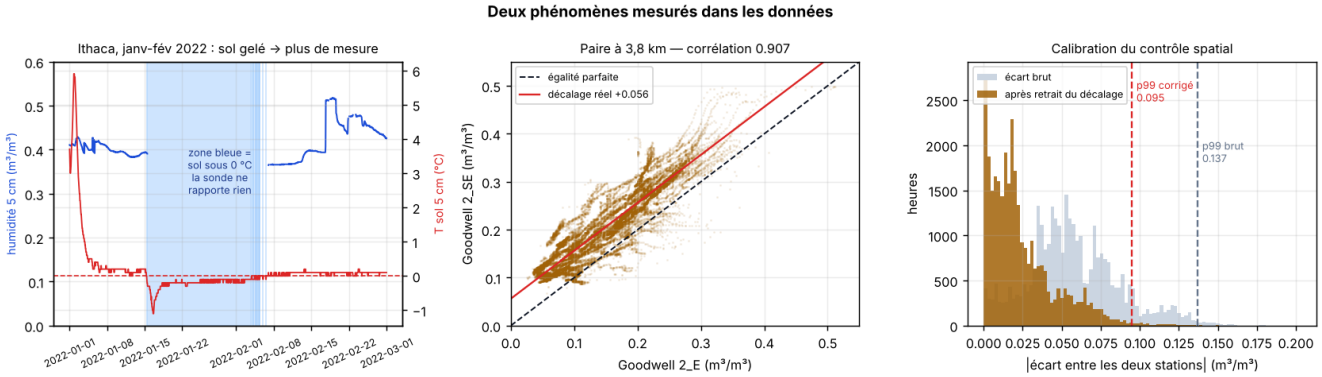


Figure 3 — À gauche, l'épisode de gel de janvier 2022 à Ithaca : dès que la température du sol passe sous zéro (zone bleue), la courbe d'humidité s'interrompt. Au centre, le nuage des deux stations jumelles se place nettement au-dessus de la diagonale d'égalité : c'est le décalage. À droite, la distribution des écarts avant et après correction de ce décalage.

4.3 Le seuil du contrôle spatial se calibre sur les données

Une fois le décalage retiré, l'écart résiduel entre les deux stations se resserre nettement :

Mesure	Écart brut	Après retrait du décalage
Écart moyen	0,058 m^3/m^3	**0,025 m^3/m^3**
Centile 99	0,137 m^3/m^3	**0,095 m^3/m^3**

Le seuil d'alerte du contrôle spatial est donc 0,095 m^3/m^3, après correction du décalage. Ce n'est pas une valeur choisie : c'est le centile 99 de ce que font réellement deux capteurs voisins en fonctionnement normal. Au-delà, l'écart sort de ce que la nature produit.

Travailler sur l'écart brut aurait donné un seuil de 0,137 — soit **44 % moins sensible**, et une injection modérée serait passée inaperçue.

Une précision sur l'usage. La corrélation des *niveaux* entre les deux stations est de 0,907, mais celle de leurs *variations horaires* n'est que de 0,415. Le contrôle spatial doit donc porter sur les niveaux corrigés du décalage, et non sur les écarts d'une heure à l'autre, trop bruités pour être exploitables.

5. Comment la sélection a abouti

Deux stations initialement retenues ont été écartées après vérification sur les quatre années — un test qui n'avait porté que sur 2025 lors de la présélection.

Station	Problème	Décision
AL_Selma_13_WNW	Panne de septembre 2023 à février 2024 : cinq mois consécutifs sans mesure, à cheval sur l'entraînement et la validation. 85,3 % de moyenne.	Remplacée par **MS_Newton_5_ENE** (100 %)
AL_Selma_6_SSE	Aucun rayonnement solaire ni température de surface sur toute la période : deux capteurs absents, pas des trous.	Abandonnée
OK_Goodwell_2_E	Panne de janvier à avril 2022. Mais sa jumelle 2_SE est à 98,9 % sur les quatre années.	Rôles inversés : 2_SE devient principale, 2_E devient la jumelle

Le piège de l'année 2022. En testant dix remplaçants possibles sur les quatre années, sept décrochent en 2022 — certains à 0 %. Il s'agit très probablement d'une campagne d'installation ou de remplacement de sondes sur le réseau. Une sélection fondée sur la seule année 2025 aurait retenu n'importe laquelle de ces stations, et le problème ne serait apparu qu'au moment de l'entraînement.

6. Ce qui est livré

Fichier	Contenu
uscrn_clean.parquet	Le dataset : 210 384 lignes, 22 colonnes, nettoyé et validé
uscrn_rapport_qualite.csv	Chaque problème traité, par station, année et colonne
USCRN_final/	Les 24 fichiers texte bruts de la NOAA, sources intactes
clean_uscrn.py	Le pipeline de nettoyage, reproductible en une commande
select_stations.py	La présélection des 115 candidates
verify_4years.py	La vérification sur les quatre années
uscrn_candidates.csv	Le classement complet des 115 stations du réseau

6.1 Points à transmettre

#	Point
1	Ne pas interpoler les heures manquantes des stations froides : elles correspondent à un sol gelé, où la mesure n'a pas de sens.
2	Avant toute comparaison entre les deux stations de Goodwell, retirer le décalage de 0,056 m^3/m^3.
3	Seuil du contrôle de cohérence spatiale : **0,095 m^3/m^3** sur les niveaux corrigés, pas sur les variations horaires.
4	Les 5 couples latitude/longitude de la section 1.1 permettent de cibler les sources de contexte sur ces points précis.