Contrôle qualité USCRN

Ce que le nettoyage a révélé, et les étapes qui restent

Résumé. Le pipeline de nettoyage a été écrit et testé sur l'année 2025 des stations retenues. Il a mis au jour trois choses que le test de sélection ne pouvait pas voir : une station dépourvue de deux capteurs entiers, deux stations limitées à deux profondeurs de sol, et une règle de détection trop naïve de ma part, depuis corrigée. Les cinq stations principales restent valides.

1. Ce qui a été fait

Le pipeline enchaîne sept étapes, dans cet ordre :

Étape	Ce qu'elle fait
1 — Parsing	Lecture des fichiers texte avec les 38 colonnes officielles de la NOAA.
2 — Horodatage	Construction d'un instant UTC unique à partir des colonnes date et heure.
3 — Valeurs manquantes	Remplacement des codes -99.000, -9999 et -99999 par de vraies valeurs vides.
4 — Drapeaux qualité	Toute valeur dont le drapeau NOAA n'est pas à zéro est invalidée.
5 — Bornes physiques	Humidité du sol entre 0 et 0,70 ; températures entre -60 et +70 °C ; rayonnement entre 0 et 1 600 W/m² ; humidité relative entre 0 et 100 %.
6 — Cohérence verticale	Un saut d'humidité à 5 cm sans réponse à 10 cm et sans pluie est signalé.
7 — Continuité	Détection des doublons et des heures absentes, puis réindexation sur une grille horaire complète.

Sortie : un fichier Parquet unique et un rapport de qualité en CSV listant chaque problème par station, par année et par colonne.

2. Les trois découvertes

2.1 Une station à qui il manque deux capteurs entiers

AL_Selma_6_SSE affiche **0 %** de rayonnement solaire et **0 %** de température de surface. Pas « peu » : rien du tout, sur les 8 760 heures. Son humidité du sol est pourtant excellente (99,7 %), ce qui explique qu'elle soit passée à travers le test de sélection — celui-ci ne regardait que cette colonne.

Conséquence. Sans rayonnement ni température de surface, impossible d'y calculer le découplage thermique ni l'énergie disponible pour l'évaporation. Cette station était proposée comme jumelle ; elle est écartée.

2.2 Deux stations limitées à deux profondeurs

AZ_Tucson_11_W et **CA_Fallbrook_5_NE** ne mesurent l'humidité qu'à 5 et 10 cm. Les profondeurs 20, 50 et 100 cm sont vides sur toute l'année.

Conséquence. Le contrôle de cohérence verticale y repose sur une seule comparaison au lieu de quatre. Ce n'est pas bloquant — l'écart entre 5 et 10 cm suffit à repérer une injection — mais il faut le savoir et l'écrire.

2.3 Ma règle de cohérence verticale était fausse

La première version signalait deux anomalies à OK_Goodwell_2_E. En examinant les lignes concernées, il pleuvait **11,4 mm** et **11,7 mm** à ces heures-là. La surface se charge, les couches profondes suivent avec retard : c'est de la physique normale, pas une anomalie.

La règle a été corrigée en ajoutant une condition : aucune pluie dans les trois heures précédentes. Après correction, **zéro anomalie** sur les sept stations.

C'est le raisonnement du projet en miniature. Valeur inhabituelle accompagnée de pluie : normal. Valeur inhabituelle sans pluie : suspect. Un détecteur qui ignore le contexte produit des fausses alertes à chaque averse.

3. État des stations après nettoyage

Complétude en pourcentage, sur l'année 2025.

Station	Hum. sol 5 cm	Profondeurs	Pluie	Solaire	T surface	Verdict
AZ_Tucson_11_W	100	2 / 5	100	100	100	**Retenue**
OK_Goodwell_2_E	96,9	5 / 5	100	100	100	**Retenue**
AL_Selma_13_WNW	100	5 / 5	100	100	100	**Retenue**
NY_Ithaca_13_E	100	5 / 5	100	100	100	**Retenue**
CA_Fallbrook_5_NE	100	2 / 5	100	100	100	**Retenue**
OK_Goodwell_2_SE	97,4	5 / 5	90,7	99,7	99,7	**Retenue** (jumelle)
AL_Selma_6_SSE	99,7	5 / 5	99,9	**0**	**0**	**Écartée**

Autres relevés : 70 valeurs invalidées par les drapeaux qualité de la NOAA sur l'ensemble des sept stations, une seule heure absente (AL_Selma_6_SSE, 9 mars à 03h UTC), et le pluviomètre de OK_Goodwell_2_SE à 90,7 % — à surveiller sur les autres années.

4. Les stations à télécharger

Climat	Station	Rôle
Aride	**AZ_Tucson_11_W**	principale
Plaines semi-arides	**OK_Goodwell_2_E**	principale
Subtropical humide	**AL_Selma_13_WNW**	principale
Continental froid	**NY_Ithaca_13_E**	principale
Méditerranéen	**CA_Fallbrook_5_NE**	principale
Plaines semi-arides	**OK_Goodwell_2_SE**	jumelle à 3,8 km — cohérence spatiale

6 stations × 4 années = 24 fichiers, environ 50 Mo au total.

Option. La paire **GA_Newton_8_W** + **GA_Newton_11_SW** (13,5 km l'une de l'autre) est irréprochable : 100 % sur toutes les colonnes et les 5 profondeurs. Elle fournirait une seconde paire jumelle, cette fois en climat humide, là où la détection est la plus difficile. Coût : 8 fichiers de plus. Elle ne remplace pas AL_Selma_13_WNW, dont l'humidité couvre une plage bien plus large (0,127-0,548 contre 0,045-0,190).

5. Les étapes qui restent

#	Étape	Détail
1	**Télécharger les 24 fichiers**	La liste des stations est déjà renseignée dans le script de téléchargement. Les fichiers arrivent dans un dossier dédié.
2	**Lancer le nettoyage sur les 4 années**	Le pipeline est écrit et validé. Il produit le Parquet propre et le rapport de qualité.
3	**Vérifier la complétude année par année**	Le test de sélection n'a porté que sur 2025. Une station peut s'être dégradée en 2022, 2023 ou 2024 : capteur remplacé, panne de plusieurs mois, recalibrage.
4	**Remplacer toute station défaillante**	Il reste 41 candidates au-dessus de 90 %. Attention : en climat continental froid il n'y en a que 4 au total, la marge y est très mince.
5	**Vérifier la continuité au changement d'année**	Le passage du 31 décembre 23h au 1er janvier 00h doit être continu après concaténation des quatre fichiers.
6	**Livrer le dataset propre**	Un Parquet unique, plus le rapport de qualité listant chaque problème traité.

Ce que ce contrôle a montré. Le test de sélection regardait une seule colonne, SOIL_MOISTURE_5. Il a laissé passer une station sans pyranomètre et deux stations à deux profondeurs. Un dataset ne se valide pas sur sa colonne cible seule : il faut vérifier chaque variable qui servira ensuite, sinon le défaut ne se découvre qu'au moment de construire les features — c'est-à-dire trop tard.