Sélection des stations USCRN

Le dataset cible du Track 2 : critères, tests, résultats et choix final

En une phrase. Sur les 159 stations du réseau USCRN, 115 remplissaient les conditions de base ; un test de disponibilité réelle sur l'année 2025 en a éliminé 60 %. Les 5 stations retenues couvrent 5 climats nettement séparés, et deux d'entre elles disposent d'une station jumelle à proximité immédiate — ce qui offre un contrôle de cohérence spatiale indépendant de SMAP et d'ERA5.

1. Le dataset USCRN

U.S. Climate Reference Network, opéré par la NOAA. Ce sont de vraies stations de mesure installées au sol, contrairement à SMAP (satellite) et ERA5 (modèle). C'est ce qui en fait la cible du Track 2 : une chaîne d'acquisition par capteur, donc attaquable de façon crédible.

Point	Détail
Source	NOAA / NCEI — produit **hourly02**, accès libre sans compte
Lien	www.ncei.noaa.gov/pub/data/uscrn/products/hourly02/
Format	fichiers texte, un par station et par année — environ 1,6 Mo chacun
Résolution	**horaire** — 8 760 lignes par an et par station
Colonnes	38 : temps, coordonnées, température, précipitations, rayonnement, humidité relative, température de surface, et **humidité du sol à 5 profondeurs** (5, 10, 20, 50, 100 cm)
Cible du projet	**SOIL_MOISTURE_5** — humidité du sol à 5 cm, la grandeur qu'on protège
Valeurs manquantes	codées **-99.000** (humidité du sol), **-9999** (températures), **-99999** (rayonnement)

Un atout propre à USCRN. Une même station fournit à la fois l'humidité du sol *et* ses causes (pluie, température, rayonnement). Les 5 profondeurs donnent en plus un contrôle de cohérence verticale gratuit : si l'humidité à 5 cm bondit sans que celle à 10 cm ne bouge, c'est physiquement impossible.

2. La contrainte de départ

Le découpage retenu par l'équipe est temporel : **2022-2023 en entraînement, 2024 en validation, 2025 en test final**. Les stations doivent donc être **les mêmes sur les quatre années**. Si elles changeaient d'une période à l'autre, une baisse de performance sur 2025 serait impossible à interpréter : on ne saurait pas si elle vient de l'année ou du changement de stations.

Trois raisons supplémentaires imposent cette continuité : les features de pluie cumulée remontent jusqu'à 30 jours en arrière et ont besoin d'un historique ; le comportement « normal » d'une station ne se construit qu'avec plusieurs années ; et le modèle One-Class apprend la signature propre de chaque capteur.

Cible : 5 stations fixes × 4 années = 20 fichiers.

3. Les critères de sélection

3.1 Trois critères éliminatoires

#	Critère	Pourquoi
1	Présence sur **les 4 années** 2022-2025	Imposé par le découpage temporel. Une station arrêtée en 2024 est inutilisable, même excellente avant.
2	**Capteur d'humidité du sol actif**	Toutes les stations n'en ont pas. L'Alaska et Hawaï en sont dépourvus (permafrost, contraintes de site) : vérifié sur AK_Fairbanks_11_NE, toutes les colonnes sol valent -99.000.
3	**Disponibilité** ≥ **90 %** sur SOIL_MOISTURE_5	Une station à 40 % de trous apporte moins de signal qu'elle n'introduit de bruit.

3.2 Deux critères de qualité

#	Critère	Pourquoi
4	**Diversité climatique**	Le Context Engine doit apprendre qu'une même variation d'humidité peut être normale dans un contexte et suspecte dans un autre. Cinq stations dans la même région reviendraient à n'apprendre qu'un seul climat.
5	**Compatibilité SMAP**	Farah doit retrouver le pixel SMAP correspondant à chaque station. SMAP mesure mal sur relief, forêt dense, zone urbaine et littoral — à éviter.

3.3 Les cinq régimes climatiques retenus

Le regroupement se fait par code d'État. Chaque groupe apporte au modèle une difficulté différente.

Groupe	États	Ce que ce climat apporte
Aride	AZ, NV, NM, UT	Sol sec en permanence : toute hausse d'humidité est forcément suspecte. Le cas le plus facile.
Plaines semi-arides	KS, NE, CO, OK, SD, ND, WY, MT	Alternance sec/humide marquée. Le cas intermédiaire.
Subtropical humide	AL, GA, SC, NC, MS, LA, FL, AR, TN, VA	Pluies fréquentes : orage et attaque se ressemblent. **Le cas difficile**.
Continental froid	MN, MI, WI, ME, NY, IA, IL, OH, PA	Gel et dégel font chuter l'humidité mesurée sans aucune attaque. Le piège à faux positifs.
Méditerranéen	CA, OR, WA, ID	Saison sèche et saison humide nettement tranchées — **le climat de la Tunisie**.

4. La méthode de test

La sélection a été automatisée (`select_stations.py`) plutôt que faite à la main, pour être reproductible et vérifiable par l'équipe. Le script enchaîne quatre étapes :

Étape	Ce qui est fait
1	Lecture des listings des quatre années et intersection : on ne garde que les stations présentes partout.
2	Exclusion de l'Alaska et de Hawaï, puis affectation de chaque station à son groupe climatique.
3	Téléchargement de l'année 2025 pour chaque candidate, et mesure de la part réelle de valeurs valides sur SOIL_MOISTURE_5 (hors -99.000).
4	Classement par groupe et export du tableau complet en CSV.

Le test ne porte que sur 2025 : c'est l'année de test final, la plus exigeante, et une station défaillante en 2025 est de toute façon inutilisable. L'extension aux trois autres années se fait au téléchargement final.

5. Les résultats

Étape	Stations restantes
Réseau USCRN complet (2025)	159
Présentes sur les 4 années 2022-2025	**156**
Hors Alaska et Hawaï, dans un groupe climatique	**115**
Disponibilité SOIL_MOISTURE_5 ≥ 90 %	**46** — soit 60 % d'élimination

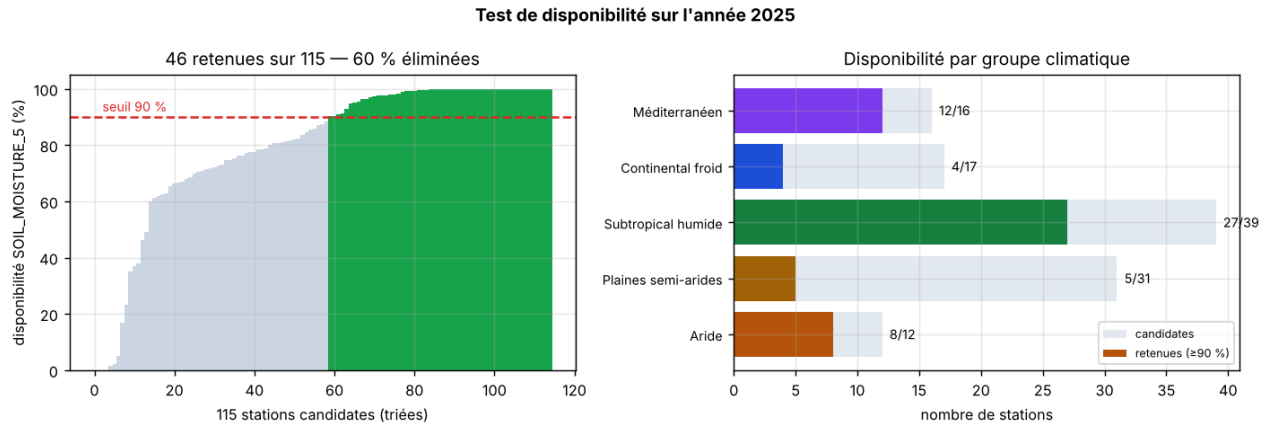


Figure 1 — À gauche, la disponibilité des 115 candidates, triée. La distribution est nettement bimodale : les stations fonctionnent bien ou pas du tout, il y a peu de cas intermédiaires. À droite, le taux de réussite par groupe climatique.

Le résultat le plus utile est la rareté par climat. Le subtropical humide offre 27 stations exploitables sur 39, mais le continental froid n'en offre que 4 sur 17, et les plaines semi-arides 5 sur 31. Pour ces deux groupes, le choix est très contraint — ce qui justifie d'avoir testé toutes les candidates plutôt que quelques-unes choisies au hasard.

6. Une trouvaille : les stations jumelles

En examinant la liste complète, plusieurs sites apparaissent **deux fois**, avec deux stations distinctes à faible distance l'une de l'autre, toutes deux exploitables :

Paire	Distance	Disponibilité
OK_Goodwell_2_E + **OK_Goodwell_2_SE**	**3,8 km**	96,9 % / 97,4 %
AL_Selma_13_WNW + **AL_Selma_6_SSE**	28,4 km	100 % / 99,7 %
GA_Newton_11_SW + GA_Newton_8_W	—	100 % / 100 %
NC_Asheville_13_S + NC_Asheville_8_SSW	—	98,2 % / 99,7 %

Pourquoi c'est précieux. Deux capteurs distants de quelques kilomètres mesurent le même sol sous la même météo. Leurs mesures doivent évoluer ensemble. Si l'une diverge et pas l'autre, l'anomalie est établie sans avoir besoin d'aucune source externe.

> Cela donne au projet un **contrôle de cohérence spatiale qui ne dépend ni de SMAP ni d'ERA5**, et une démonstration directe pour la soutenance : on injecte une attaque sur une station, sa jumelle ne bouge pas, la contradiction est immédiate et visible à l'œil nu.

La paire de Goodwell est la plus intéressante : 3,8 km seulement, donc même sol, même météo, même régime hydrique. Celle de Selma est plus éloignée (28 km) et les deux stations montrent des plages d'humidité différentes (0,127-0,548 contre 0,036-0,294), signe de sols distincts — utile quand même, mais moins directement comparable.

7. Le choix final

Climat	Station	Dispo	Pluie 2025	T moy	Latitude	Longitude
Aride	**AZ_Tucson_11_W**	100 %	185 mm	22,4 °C	32.24	-111.17
Plaines semi-arides	**OK_Goodwell_2_E**	96,9 %	461 mm	14,2 °C	36.60	-101.59
Subtropical humide	**AL_Selma_13_WNW**	100 %	1 349 mm	17,8 °C	32.46	-87.24
Continental froid	**NY_Ithaca_13_E**	100 %	1 035 mm	7,9 °C	42.44	-76.25
Méditerranéen	**CA_Fallbrook_5_NE**	100 %	382 mm	17,4 °C	33.44	-117.19

Jumelles proposées en complément : **OK_Goodwell_2_SE** (36.57 / -101.61) et **AL_Selma_6_SSE** (32.33 / -86.98) — 8 fichiers de plus.

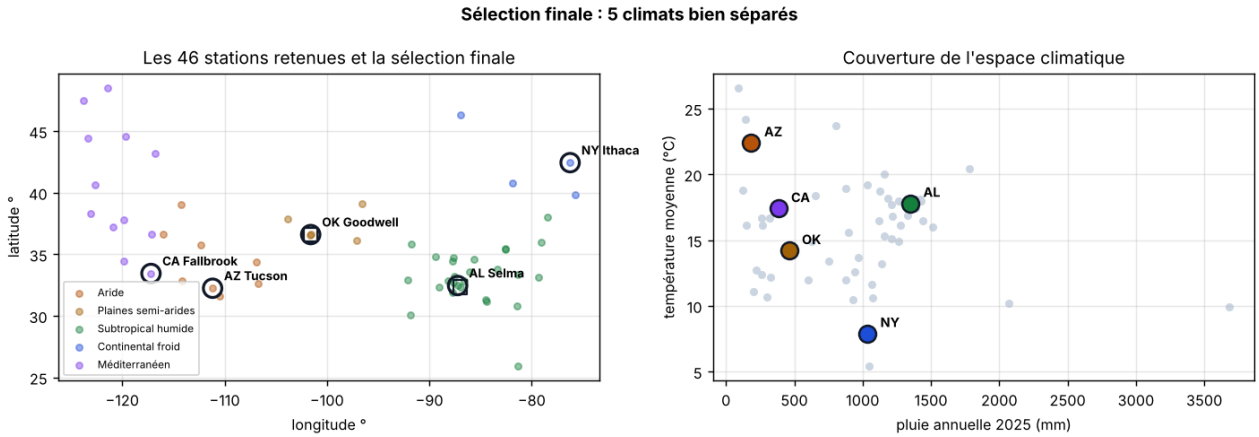


Figure 2 — À gauche, position des 46 stations retenues ; les cercles noirs marquent la sélection finale, les carrés les jumelles. À droite, les cinq stations dans l'espace pluie-température : elles occupent des zones bien distinctes, ce qui était l'objectif.

7.1 Les deux arbitrages

Plaines : Goodwell plutôt que Stillwater. Stillwater arrivait premier au classement (99,9 % contre 96,9 %), mais il reçoit **896 mm** de pluie par an — presque autant que les stations subtropicales. Il aurait fait doublon avec l'Alabama au lieu d'apporter un climat distinct. Goodwell, dans le panhandle de l'Oklahoma, reçoit **461 mm** : c'est un vrai régime semi-aride. Et il dispose d'une jumelle à 3,8 km. Trois points de disponibilité sacrifiés pour un climat réellement différent et un contrôle spatial gratuit.

Méditerranéen : Fallbrook plutôt que Bodega. Les deux sont à 100 %. Bodega est sur la côte pacifique, 599 mm et brouillard fréquent — or SMAP mesure mal le littoral, ce qui compliquerait l'alignement spatial. Fallbrook est plus sec (382 mm) et plus chaud (17,4 °C), donc plus proche du climat tunisien.

Réserve à signaler. L'humidité minimale de Fallbrook est de 0,113 : le sol ne s'assèche jamais complètement, probablement du fait d'irrigation à proximité. Si l'équipe préfère une amplitude plus large, Bodega (minimum 0,018) reste le repli naturel.

8. Ce que cela fournit au reste de l'équipe

Pour	Ce qui est livré
Farah (SMAP)	Les 5 couples latitude/longitude, pour identifier les pixels SMAP correspondants.
Ghaya (ERA5)	Les mêmes coordonnées, pour cibler le téléchargement ERA5 sur ces points précis plutôt que sur une zone entière.
Firas (ISMN)	La grille climatique utilisée ici, applicable telle quelle pour choisir des stations ISMN comparables.
Équipe cyber	Le régime hydrique de chaque station, qui conditionne la stratification de l'injection d'attaques.

Fichiers. `select_stations.py` (sélection reproductible), `download_final.py` (téléchargement des 20 fichiers), `uscrn_candidates.csv` (classement complet des 115 candidates avec coordonnées).

Décision à prendre en réunion : retient-on 5 stations, ou 5 + les 2 jumelles ? Le coût est de 8 fichiers supplémentaires ; le gain est un contrôle de cohérence spatiale indépendant de toute source externe.