# USCRN — Données brutes, processus de nettoyage et dataset final

Oct 10, 2026 · @Aziz chouaia

## Résumé

On est parti de 24 fichiers texte bruts NOAA (6 stations × 4 ans). On en a fait un seul fichier Parquet propre de 210 384 lignes horaires. L'humidité du sol à 5 cm, notre variable cible, est complète à 97,4 %.

| | Avant (brut) | Après (nettoyé) |
|---|---|---|
| Fichiers | 24 `.txt` à largeur fixe, sans en-tête | 1 `uscrn_clean.parquet` |
| Colonnes | 38 colonnes NOAA, dont 7 drapeaux qualité | 23 colonnes utiles + 1 drapeau d'incohérence |
| Lignes | 210 384 | 210 384 (35 064 par station, aucune heure absente) |
| Valeurs manquantes | Codées en -99 / -9999 / -99999, donc lues comme des nombres | 463 194 codes convertis en vraies valeurs vides (NaN) |
| Valeurs douteuses | 420 valeurs avec un drapeau NOAA ≠ 0, 7 hors bornes physiques | Toutes invalidées |
| Temps | Date et heure séparées, en UTC et en heure locale | Une colonne `time` en UTC |
| Traçabilité | Aucune | `uscrn_rapport_qualite.csv` : 590 lignes, chaque correction par station, année et colonne |

## Les données brutes

La source est le produit NOAA USCRN Hourly02. Il y a un fichier texte par station et par année, nommé `CRNH0203-<année>-<station>.txt`, avec une ligne par heure (source).

**Contenu d'une ligne (38 colonnes)**

- Identifiant et position : `WBANNO`, `LATITUDE`, `LONGITUDE`, version du logger
- Temps : `UTC_DATE`, `UTC_TIME`, `LST_DATE`, `LST_TIME`. L'horodatage marque la **fin** de l'heure mesurée.
- Air : température (`T_CALC`, `T_HR_AVG`, `T_MAX`, `T_MIN`), pluie `P_CALC` (mm/h), humidité relative `RH_HR_AVG`
- Rayonnement `SOLARAD` (+ max/min) et température de surface `SUR_TEMP` (+ max/min), chacun avec son drapeau qualité
- Sol : humidité `SOIL_MOISTURE_5/10/20/50/100` ($m^3/m^3$) et température `SOIL_TEMP_5/10/20/50/100` (°C)

**Problèmes du brut**

| Problème | Exemple | Volume constaté |
|---|---|---|
| Valeur manquante codée comme un nombre | -99.000 pour l'humidité du sol, -9999 pour les températures, -99999 pour le rayonnement | 463 194 valeurs |
| Profondeurs absentes | Tucson et Fallbrook ne mesurent qu'à 5 et 10 cm | ~73 000 valeurs par colonne 20/50/100 cm |
| Trous pendant le gel | Ithaca : 701 des 727 heures manquantes ont un sol sous 1 °C | 96 % des trous d'Ithaca |
| Drapeaux qualité NOAA ≠ 0 | Rayonnement et température de surface | 420 valeurs |
| Valeurs physiquement impossibles | `SUR_TEMP_MAX` hors de [-60, 70] °C | 7 valeurs |
| Stations inutilisables | Pannes de plusieurs mois, capteurs absents, 0 % de sol en 2022 | 4 stations écartées (section suivante) |

L'humidité du sol n'a pas de drapeau qualité dans Hourly02 : la NOAA écarte déjà elle-même les valeurs mauvaises en les mettant à -99.

## Sélection des stations

Sur les 115 stations du réseau, on en a gardé 5 principales, une par climat, plus une station jumelle située à 3,8 km pour le contrôle de cohérence spatiale.

1. `select_stations.py` : on a classé les 115 candidates selon la disponibilité de `SOIL_MOISTURE_5` en 2025 (résultat dans `uscrn_candidates.csv`).

2. `verify_4years.py` : on a vérifié les meilleures candidates sur 2022–2025 (`verif_4ans.csv`). Sur 10 remplaçants testés, 7 décrochent en 2022, certains à 0 %.
3. `download_final.py` : on a téléchargé les 24 fichiers retenus dans `USCRN_final/`.

| Station | Rôle | Décision |
|---|---|---|
| AZ_Tucson_11_W | Aride | Gardée |
| OK_Goodwell_2_SE | Plaines semi-arides | Gardée, promue principale (98,9 %) |
| MS_Newton_5_ENE | Subtropical humide | Gardée, remplace AL_Selma_13_WNW |
| NY_Ithaca_13_E | Continental froid | Gardée |
| CA_Fallbrook_5_NE | Méditerranéen | Gardée, la plus proche du climat tunisien |
| OK_Goodwell_2_E | Jumelle de Goodwell_2_SE | Gardée, malgré une panne de janvier à avril 2022 |
| AL_Selma_13_WNW | — | Écartée : panne de septembre 2023 à février 2024 (85,3 %) |
| AL_Selma_6_SSE | — | Écartée : aucun rayonnement ni température de surface |
| AL_Clanton_2_NE | — | Écartée : 0 % d'humidité du sol en 2022 et 2023 |
| GA_Newton_8_W | — | Écartée : 0 % en 2022 |

## Processus de nettoyage

Tout le nettoyage tient en un script reproductible : `python clean_uscrn.py USCRN_final/`. Il applique 7 étapes dans cet ordre, puis note chaque correction dans le rapport qualité.

| # | Étape | Règle appliquée | Effet sur les données |
|---|---|---|---|
| 1 | Parsing | Lecture avec les 38 noms de colonnes officiels NOAA | 24 fichiers lus, 210 384 lignes |
| 2 | Horodatage | `UTC_DATE` + `UTC_TIME` sont fusionnés en une colonne `time` (UTC) | Une clé temporelle unique |

| # | Étape | Règle appliquée | Effet sur les données |
|---|---|---|---|
| 3 | Valeurs manquantes | -99 (sol), -9999 (températures, pluie, humidité relative), -99999 (rayonnement) deviennent NaN | 463 194 valeurs |
| 4 | Drapeaux NOAA | Si le drapeau est différent de 0, la valeur liée est invalidée. Les colonnes de drapeaux sont ensuite supprimées. | 420 valeurs |
| 5 | Bornes physiques | Sol 0–0,70 $m^3/m^3$ ; températures -60 à 70 °C ; rayonnement 0–1 600 $W/m^2$ ; pluie 0–200 mm/h ; humidité relative 0–100 % | 7 valeurs |
| 6 | Cohérence verticale | Un saut de plus de 0,10 à 5 cm, sans réponse à 10 cm (moins de 0,01) et sans pluie sur 3 h, est marqué `flag_incoherence_verticale` | 0 cas |
| 7 | Continuité | On supprime les doublons, puis on réindexe sur une grille horaire complète | 0 doublon, 0 heure absente |

### Choix importants

- **Rien n'est interpolé.** Une valeur manquante reste vide. Dans un sol gelé, la sonde diélectrique ne mesure plus rien : combler ces trous reviendrait à inventer des données.
- **L'étape 6 a été corrigée.** La première version signalait deux « anomalies » à Goodwell_2_E. Or il pleuvait 11,4 et 11,7 mm à ces heures-là. On a donc ajouté la condition « pas de pluie » : une hausse avec de la pluie est normale, une hausse sans pluie est suspecte.
- **On ne supprime aucune ligne.** Seules des valeurs sont invalidées. Chaque station garde exactement 35 064 heures, ce qui simplifie l'alignement avec ERA5 et SMAP.

## Le dataset nettoyé

`uscrn_clean.parquet` contient une ligne par station et par heure, du 1er janvier 2022 à 01:00 UTC au 1er janvier 2026 à 00:00 UTC. La clé est `time` + `station`.

### Schéma (23 colonnes)

| Groupe | Colonnes | Unité | Valeurs vides |
|---|---|---|---|
| Clé | `time`, `station`, `annee` | UTC | 0 % |

| Groupe | Colonnes | Unité | Valeurs vides |
|---|---|---|---|
| Position | `LATITUDE`, `LONGITUDE` | degrés | 0 % |
| **Cible** | `SOIL_MOISTURE_5` | $m^3/m^3$ | 2,6 % |
| Sol, 10 cm | `SOIL_MOISTURE_10`, `SOIL_TEMP_5`, `SOIL_TEMP_10` | $m^3/m^3$, °C | 1,7 – 2,5 % |
| Sol, 20/50/100 cm | `SOIL_MOISTURE_*`, `SOIL_TEMP_*` | $m^3/m^3$, °C | ~35 % (absentes à Tucson et Fallbrook) |
| Météo | `T_HR_AVG`, `T_MAX`, `T_MIN`, `P_CALC`, `RH_HR_AVG` | °C, mm/h, % | ⩽ 0,7 % |
| Énergie | `SOLARAD`, `SUR_TEMP` | $W/m^2$, °C | 0,1 % |
| Contrôle | `flag_incoherence_verticale` | booléen | 0 cas vrai |

### Stations et qualité de la cible

| Station | Climat | Lat. / Lon. | Pluie/an | `SOIL_MOISTURE_5` vide |
|---|---|---|---|---|
| CA_Fallbrook_5_NE | Méditerranéen | 33.44 / -117.19 | 428 mm | 0,0 % |
| MS_Newton_5_ENE | Subtropical humide | 32.34 / -89.07 | 1 439 mm | 0,0 % |
| OK_Goodwell_2_SE | Plaines semi-arides | 36.57 / -101.61 | 443 mm | 1,1 % |
| NY_Ithaca_13_E | Continental froid | 42.44 / -76.25 | 1 047 mm | 2,1 % |
| AZ_Tucson_11_W | Aride | 32.24 / -111.17 | 223 mm | 2,4 % |
| OK_Goodwell_2_E | Jumelle (3,8 km) | 36.60 / -101.59 | 454 mm | 9,8 % |

Le découpage prévu est le suivant : entraînement 2022–2023, validation 2024, test 2025. Aucune station principale ne descend sous 92 % de données disponibles sur une période.

**Fichiers livrés** : `uscrn_clean.parquet`, `uscrn_rapport_qualite.csv`, `USCRN_final/` (les 24 bruts, intacts), `clean_uscrn.py`, `select_stations.py`, `verify_4years.py`, `download_final.py`, `uscrn_candidates.csv`.

## Règles d'usage et limites

Ce qu'il faut savoir avant d'utiliser le dataset (Attack Engine, alignement ERA5/SMAP, détecteurs) :

1. **Ne pas interpoler les trous des stations froides.** Ils correspondent à un sol gelé. C'est un angle mort hivernal du détecteur, et il faut le documenter.
2. **Retirer le décalage de 0,056 m³/m³ entre les deux Goodwell** avant de les comparer. Leurs niveaux sont corrélés à 0,907, mais Goodwell_2_SE lit plus haut que 2_E dans 95,3 % des heures.
3. **Seuil du contrôle spatial : 0,095 m³/m³**, appliqué aux niveaux corrigés, pas aux variations horaires (corrélées à seulement 0,415). C'est le centile 99 de l'écart normal entre les deux stations.
4. **Convention de temps** : `time` est en UTC et marque la fin de l'heure. Il faut en tenir compte pour l'alignement avec ERA5.
5. **Cohérence verticale limitée** à la comparaison 5 cm / 10 cm pour Tucson et Fallbrook.
6. **Coordonnées** : les 6 couples lat/lon du tableau ci-dessus servent à cibler les pixels SMAP et la grille ERA5.

### À faire

- [ ] Ajouter une colonne `flag_sol_gele` (sol à 5 cm sans valeur et température du sol sous 1 °C)
- [ ] Ajouter une colonne Goodwell_2_E corrigée du décalage
- [ ] Calculer la cohérence verticale après la réindexation horaire, et non avant
- [ ] Déposer les fichiers dans le dossier Drive `data/NCEI NOAA` et mettre à jour le Task tracker